数据准备与评价设计
Data Preparation and Evaluation

E1	E2	E3	E4	E5	E6
工具映射	查询契约	科学语义	请求边界	指导消融	运行一致性
28题 × 3组	21场景 × 3次	32题 × 2配置 × 3次	35题 × 3次 + 15场景	56题 × 11配置 × 3次	32任务 × 5次

数据准备
Data Preparation

参考答案与可见材料
分别归档题面、工具说明与参考答案
记录模型可见材料及访问权限

运行记录与数据来源
区分实站快照、固定回包与压力样本
保存请求、回答、工具轨迹及执行状态
关联调用计划、执行记录与数据来源

结果整理与完整性核验
统一坐标、参数单位与数据表示
核对记录身份、内容摘要与结果完整性

评价与统计
Evaluation and Statistics

程序核验与语义评分
程序核验工具、参数、字段与返回行集
科学陈述按固定证据量规评分

统计单位与重复汇总
按任务、来源、断言或场景确定分母
运行完成率与任务通过率分别统计
E1：组间均值与同题同维中位数

组间比较与运行一致性
E5：相同工具下配对比较指导效果
E6：比较工具、参数、数据与核心结论
按任务或来源估计差值与置信区间